

Rúbrica para la evaluación de definiciones terminológicas generadas por modelos de lenguaje: diseño, aplicación y transferibilidad a otros ámbitos especializados

M. Isabel Santamaría-Pérez

ORCID: 0000-0002-6264-1837

Ovidia Martínez Sánchez

ORCID: 0009-0003-1557-4816

Universidad de Alicante

Grupo EPA — Español Profesional y Académico

Proyecto Neotermed4All — CIAICO/2024/81

Versión 1.0 · 2026

Artículo metodológico e instrumento de evaluación

Licencia CC BY 4.0

Resumen

Este artículo metodológico presenta una rúbrica de evaluación diseñada para valorar la calidad de definiciones terminológicas generadas por modelos de lenguaje. El instrumento surge de la experiencia de elaboración y revisión del *Vocabulario de Reproducción Asistida*, en el que se compararon definiciones producidas por distintos sistemas de inteligencia artificial con definiciones humanas de referencia. La rúbrica propone una evaluación analítica de la definición en función de su categoría conceptual o hiperónimo, sus rasgos distintivos esenciales, su forma definitoria, su precisión léxica y especialización, su compatibilidad con una definición de referencia y su adecuación al destinatario. Aunque el instrumento se ha desarrollado a partir de un dominio médico concreto, su estructura responde a principios generales de la terminología y de la redacción lexicográfica, por lo que puede replicarse en otros ámbitos de especialidad mediante la adaptación del campo temático, del perfil de usuario y de las definiciones de referencia. El artículo describe el diseño de la rúbrica, el procedimiento de aplicación, las condiciones de replicabilidad y las posibles utilidades del instrumento para la evaluación de recursos terminológicos, la comparación de modelos de lenguaje y la mejora de *prompts* orientados a la generación de definiciones especializadas.

Palabras clave: rúbrica de evaluación; definición terminológica; terminología; modelos de lenguaje; inteligencia artificial generativa; reproducción asistida; lexicografía especializada; replicabilidad.

Abstract

This methodological article presents a rubric designed to evaluate the accuracy of terminological definitions produced by large language models. It was developed based on the experience of compiling and reviewing the *Vocabulario de Reproducción Asistida*, for which AI-generated definitions were systematically compared with validated human reference definitions. The rubric provides an analytical assessment across six dimensions: conceptual category, essential distinctive features, definitional form, lexical precision and specialisation, compatibility with a reference definition, and suitability for the intended audience. Although the instrument originates in a specific biomedical domain, its structure is based on general principles of terminology and specialised lexicographic writing. This means it can be transferred to other subject fields by adapting the thematic domain, user profile, and reference definitions. The article describes the design of the rubric, how it is applied and the conditions for replicability. It also explores potential applications in evaluating terminological resources, comparing language models and enhancing prompts for generating specialised definitions.

Keywords: assessment rubric; terminological definition; terminology; language models; generative AI; assisted reproduction; specialized lexicography; replicability.

1. Introducción

La investigación reciente sobre inteligencia artificial (IA) generativa aplicada a la lexicografía y la terminología muestra un consenso cada vez más claro: los modelos de lenguaje pueden producir definiciones formalmente correctas y útiles como punto de partida, pero no garantizan por sí solos la precisión conceptual, la adecuación terminológica ni la fiabilidad suficiente para su incorporación directa a recursos especializados. En lexicografía, trabajos como los de De Schryver (2023), Lew (2023, 2025) y Jakubíček y Rundell (2023) han mostrado tanto el potencial de ChatGPT para generar entradas de diccionario como sus limitaciones, especialmente en la gestión de la polisemia, la selección de acepciones, la consistencia formal y la detección de errores. En el ámbito hispanohablante, Alonso Ramos (2023), Tarp y Nomdedeu-Rull (2024), Fuertes-Olivera y Tarp (2025) o Fuentes Morán *et al.* (2024) coinciden en señalar que la IA generativa puede aumentar la productividad en tareas lexicográficas y terminológicas, pero siempre dentro de un modelo de colaboración humano-IA, en el que la supervisión experta continúa siendo indispensable. Esta necesidad resulta aún más evidente en contextos especializados, donde una definición no solo debe ser lingüísticamente aceptable, sino también conceptualmente correcta, verificable y adecuada al dominio de conocimiento correspondiente.

En terminología, esta línea de investigación se ha desarrollado en torno a la terminografía asistida por IA, la generación de definiciones especializadas y la desteminologización de contenidos para públicos no expertos. San Martín (2024) plantea que la IA generativa abre la posibilidad de una posesición terminográfica, en la que el modelo produce una primera versión de la definición y el terminólogo la corrige o refina; Heinisch (2025) advierte, sin embargo, de la falta de exactitud y consistencia de los LLM en tareas como la extracción de términos, la redacción de definiciones y la organización conceptual. En el ámbito biosanitario, Varela Salinas y Godoy Lorenzatto (2024) y Vidal Sabanés y Da Cunha (2025) muestran que ChatGPT puede apoyar tareas de clarificación terminológica y selección de variantes comprensibles, pero que sus resultados no

alcanzan los estándares de precisión y cobertura de la metodología terminográfica clásica sin validación experta.

La generación automática de definiciones terminológicas mediante modelos de lenguaje plantea una cuestión metodológica central: cómo valorar si una definición generada no solo es gramaticalmente aceptable, sino también conceptualmente adecuada, terminológicamente precisa y útil para un destinatario concreto. En los recursos terminológicos especializados, la definición no es una explicación libre del término, sino una unidad discursiva sometida a restricciones conceptuales, formales y comunicativas. En este contexto, una rúbrica analítica se justifica como instrumento necesario para convertir esa validación en un procedimiento explícito, replicable y comparable: permite evaluar separadamente la categoría conceptual, los rasgos distintivos, la forma definitoria, la precisión léxica, la compatibilidad con una referencia validada y la adecuación al destinatario.

La rúbrica que se presenta en este artículo se ha concebido como un instrumento de evaluación aplicable a definiciones terminológicas generadas por modelos de lenguaje. Su punto de partida empírico es el trabajo realizado en el *Vocabulario de Reproducción Asistida*¹, un recurso terminológico en español orientado a estudiantes universitarios de ciencias de la salud. A partir de esta experiencia, se identificaron criterios relevantes para evaluar la calidad de las definiciones producidas por sistemas de inteligencia artificial y para compararlas con definiciones humanas de referencia.

El objetivo de este artículo es doble. En primer lugar, documentar la rúbrica como recurso de investigación citable y reutilizable. En segundo lugar, explicar por qué el instrumento no se limita al ámbito de la reproducción asistida, sino que se puede transferir a definiciones terminológicas de cualquier campo especializado siempre que se ajusten los parámetros de dominio, destinatario y referencia conceptual.

2. Contexto de desarrollo del instrumento

La rúbrica se ha creado en el marco de una comparación entre definición de referencia validada y definiciones generadas por cinco modelos de inteligencia artificial. El ámbito de prueba se ha centrado en la terminología especializada de la reproducción asistida en español, en concreto en dos subdominios específicos: enfermedades y trastornos de fertilidad y técnicas y tratamientos de reproducción asistida.

El destinatario prototipo del vocabulario era un estudiante universitario de ciencias de la salud. Esta decisión ha condicionado tanto el nivel de especialización del léxico como la densidad informativa esperable en las definiciones. Por ello, la calidad de una definición no se entiende únicamente como exactitud conceptual, sino también como adecuación comunicativa a un perfil de usuario concreto.

El proceso de generación de definiciones con IA se ha apoyado en un *prompt* orientado a obtener definiciones con forma lexicográfica y terminológica. Dicho *prompt* exigía que la definición siguiera, siempre que fuera posible, el patrón de género próximo y diferencia específica; que comenzara con un descriptor o hiperónimo adecuado; que constara de una sola oración; que evitara fórmulas metadiscursivas; y que mantuviera un nivel de especialidad apropiado para estudiantes universitarios de ciencias de la salud.

¹ Página web: <https://vocabulario.neotermed.org/>

3. Objetivos de la rúbrica

- Evaluar de manera sistemática la calidad de definiciones terminológicas generadas por modelos de lenguaje.
- Separar la evaluación conceptual de la mera coincidencia literal con una definición humana de referencia.
- Identificar fortalezas y debilidades de las definiciones generadas en categorías observables y puntuables.
- Facilitar la comparación entre modelos, versiones de un mismo modelo o estrategias de *prompting*.
- Ofrecer un instrumento replicable y adaptable a otros dominios terminológicos.

4. Diseño metodológico

4.1. Unidad de análisis

La unidad de análisis es cada definición terminológica generada para un término especializado. La rúbrica se aplica de forma independiente a cada definición, con independencia del modelo que la haya producido. El resultado es una puntuación analítica por criterio y una puntuación global que permite interpretar el grado de adecuación de la definición.

4.2. Principio de comparación

La evaluación toma como referencia una definición humana o validada del concepto. No se exige coincidencia literal: una definición puede emplear otras palabras y ser válida si mantiene el núcleo conceptual, no contradice rasgos esenciales y se formula de acuerdo con las convenciones de la definición terminológica. Este principio evita que la rúbrica penalice reformulaciones correctas y permite valorar la calidad intrínseca de la definición.

4.3. Escala de puntuación

Cada criterio puede valorarse en una escala de 0 a 5 puntos. El valor 5 corresponde a una definición excelente en el criterio evaluado; el valor 0 indica ausencia, inadecuación grave o incompatibilidad con el concepto de referencia. La suma de los criterios permite obtener una valoración global, aunque la interpretación cualitativa debe considerar también las observaciones del evaluador.

Cuando una definición contenga una alucinación factual —información que contradiga de forma demostrable el concepto o lo desplace a un ámbito distinto—, se aplicará una penalización de hasta -3 puntos sobre la puntuación total, en función de la gravedad de la desviación. Esta penalización se registrará en la ficha de evaluación y deberá ir acompañada de una justificación en el apartado de observaciones.

5. Criterios de evaluación

Tabla 1. Criterios de evaluación de la rúbrica

Criterio			Objeto de evaluación	Aplicabilidad a otros ámbitos
Categoría	conceptual	o	Valora si la definición comienza con un descriptor que sitúa correctamente el término dentro de su clase conceptual.	Debe adaptarse al tipo de entidad, terminología y destinatario propios del dominio especializado seleccionado.
hiperónimo				

Criterio	Objeto de evaluación	Aplicabilidad a otros ámbitos
Rasgos distintivos esenciales	Valora si la definición incluye los rasgos que diferencian el concepto de otros próximos en el mismo campo.	Debe adaptarse al tipo de entidad, terminología y destinatario propios del dominio especializado seleccionado.
Forma definitoria	Valora si la respuesta adopta una formulación lexicográfica y terminológica, breve, controlada y no enciclopédica.	Debe adaptarse al tipo de entidad, terminología y destinatario propios del dominio especializado seleccionado.
Precisión léxica y especialización	Valora el uso de terminología especializada adecuada al dominio y al nivel esperado.	Debe adaptarse al tipo de entidad, terminología y destinatario propios del dominio especializado seleccionado.
Adecuación al destinatario	Valora si la definición es comprensible y útil para el perfil de usuario definido, sin simplificación excesiva ni tecnicismo innecesario.	Debe adaptarse al tipo de entidad, terminología y destinatario propios del dominio especializado seleccionado.
Compatibilidad con la definición de referencia (opcional)	Valora si la definición mantiene el núcleo conceptual y no contradice ni reduce de forma problemática el alcance del término.	Debe adaptarse al tipo de entidad, terminología y destinatario propios del dominio especializado seleccionado.

La adecuación al destinatario puede aplicarse de dos formas. En estudios donde el perfil de usuario sea decisivo, puede añadirse como criterio independiente. En estudios más centrados en la estructura terminológica, puede tratarse como dimensión transversal vinculada a la precisión léxica, a la selección de rasgos y a la densidad informativa de la definición.

La compatibilidad con la definición de referencia es un criterio opcional. Su aplicación requiere disponer de una fuente terminológica validada para el término evaluado, lo que no siempre es posible: en dominios emergentes, en términos sin entrada en recursos especializados o en estudios centrados exclusivamente en las propiedades formales de la definición, puede prescindirse de este criterio sin que ello afecte a la validez de la evaluación con los cinco criterios principales.

6. Procedimiento de aplicación

Tabla 2. Fases del procedimiento de aplicación

Fase	Descripción
1. Selección de términos	Definir el conjunto de términos que se evaluará y clasificarlo por tipo conceptual o subdominio.
2. Preparación de referencias	Disponer de una definición humana, validada o procedente de una fuente fiable para cada término.
3. Generación de definiciones	Aplicar un <i>prompt</i> controlado a uno o varios modelos de lenguaje, preferiblemente en sesiones independientes para reducir contaminación contextual.
4. Evaluación analítica	Asignar puntuaciones de 0 a 5 en cada criterio y registrar observaciones justificativas.
5. Control de errores	Registrar alucinaciones, contradicciones factuales o respuestas que no adopten forma definitoria.

Fase	Descripción
6. Interpretación	Analizar resultados por término, modelo, tipo conceptual y criterio para identificar patrones de mejora o sesgo.

7. Transferibilidad y replicabilidad

La rúbrica es transferible porque sus criterios no dependen de contenidos propios de la reproducción asistida, sino de propiedades generales de una buena definición terminológica. Toda definición especializada debe identificar una categoría conceptual, seleccionar rasgos distintivos, mantener una formulación definitoria, emplear léxico adecuado y ajustarse a un destinatario. Estos requisitos son aplicables a ámbitos como el derecho, la economía, la ingeniería, la lingüística, la educación, la medicina, la informática o las ciencias ambientales.

La transferencia exige, sin embargo, una adaptación controlada. En cada nuevo dominio deben redefinirse los tipos conceptuales esperables, las fuentes de referencia, el nivel de especialización del usuario, los ejemplos calibrados y los posibles errores característicos de los modelos. En un vocabulario jurídico, por ejemplo, el hiperónimo puede corresponder a una figura procesal, una institución o un acto administrativo; en un vocabulario de ingeniería, puede corresponder a un componente, un proceso, una magnitud o un dispositivo.

La replicabilidad se garantiza si el estudio documenta el *prompt* utilizado, el conjunto de términos, las definiciones de referencia, el perfil del destinatario, la escala de puntuación, las instrucciones para los evaluadores y los criterios para registrar alucinaciones o respuestas no definitorias. La publicación de estos materiales junto con la rúbrica permite que otros investigadores reproduzcan el procedimiento o lo adapten a sus propios recursos terminológicos.

Por ello, es importante seguir un protocolo de adaptación a otros dominios:

1. Delimitar el dominio especializado y el subdominio terminológico.
2. Definir el destinatario: experto, estudiante universitario, profesional en formación, paciente, público general u otro perfil.
3. Construir o seleccionar definiciones de referencia validadas.
4. Revisar los hiperónimos esperables para los tipos de término del dominio.
5. Ajustar ejemplos calibrados de 0 a 5 puntos con términos propios del campo.
6. Precisar qué se considerará tecnicismo necesario, tecnicismo innecesario o simplificación problemática.
7. Aplicar la rúbrica con al menos dos evaluadores cuando se busque fiabilidad interevaluador.
8. Documentar cambios respecto de la versión original de la rúbrica.

8. Aplicación de la rúbrica a dos casos de prueba

A continuación, se muestran dos aplicaciones de la rúbrica con el *prompt* controlado. Los términos seleccionados tienen un valor diagnóstico, ya que cada uno pone de manifiesto un tipo de dificultad diferente y permite observar cómo responde la rúbrica ante problemas terminológicos distintos. Cabe señalar que estas respuestas se obtuvieron en mayo de 2026 mediante las versiones gratuitas de cinco sistemas conversacionales: ChatGPT, basado en GPT-5.5; Claude, basado en Claude Sonnet 4.6; Gemini, basado en Gemini 3 Flash; Perplexity, con selección automática sobre la familia Sonar; y Microsoft Copilot, basado en GPT-5 en modo Smart.

Ejemplo 1. *antiaging ovárico*

Definición de referencia: Estrategia médica preventiva (también denominada *rejuvenecimiento ovárico*) en reproducción asistida que busca retrasar los efectos del envejecimiento biológico del ovario. Consiste en la criopreservación prematura de ovocitos o tejido ovárico para preservar la calidad folicular, restaurar la fertilidad y posponer la menopausia mediante su posterior reimplante.

Tabla 3. Definiciones generadas por los cinco modelos

Modelo	Definición generada
IA1 ChatGPT² (GPT-5.5)	<i>Conjunto de intervenciones médicas y biotecnológicas destinadas a preservar la reserva ovárica y retrasar el envejecimiento funcional del ovario en reproducción asistida.</i>
IA2 Claude³ (Claude Sonnet 4.6)	<i>Conjunto de intervenciones médicas dirigidas a preservar o mejorar la reserva y la función ovárica en mujeres con envejecimiento gonadal prematuro o avanzado, con el fin de optimizar sus posibilidades reproductivas.</i>
IA3 Gemini⁴ (Gemini 3 Flash)	<i>Estrategia terapéutica o preventiva, en el ámbito de las técnicas de reproducción asistida, orientada a ralentizar el declive fisiológico de la reserva ovocitaria y optimizar la calidad de los gametos mediante intervenciones farmacológicas, nutricionales o de medicina regenerativa, con el fin de prolongar la ventana fértil de la mujer o mejorar las tasas de éxito en tratamientos de fertilidad.</i>
IA4 Perplexity⁵ (Sonar)	<i>Estrategia terapéutica de reproducción asistida orientada a preservar o mejorar la función ovárica mediante intervenciones hormonales, celulares o moleculares que retrasan el deterioro asociado a la edad.</i>
IA5 Copilot⁶ (GPT-5)	<i>Definición: Intervención biomédica orientada a estrategias de rejuvenecimiento ovárico que busca preservar o mejorar la función folicular mediante técnicas celulares, hormonales o regenerativas. [Si quieres, puedo ampliar sobre técnicas específicas o sobre su evidencia clínica actual.]</i>

Tabla 4. Evaluación analítica de las definiciones — *antiaging ovárico*

Criterio	IA1 ChatGPT	IA2 Claude	IA3 Gemini	IA4 Perplexity	IA5 Copilot
C1. Categoría conceptual	4	4	3	2	3
C2. Rasgos distintivos	2	2	3	2	2
C3. Forma definitoria	5	4	3	5	1
C4. Precisión léxica	4	4	4	3	3
C5. Adecuación al destinatario	4	3	3	4	3
Penalización	0	0	0	0	0
PUNTUACIÓN TOTAL (máx. 25)	19	17	16	16	12
C6. Compatibilidad con referencia (opcional, +1)	No	No	No	No	No

En **C1**, Perplexity obtiene la puntuación más baja (2) porque su hiperónimo *estrategia terapéutica* contradice el carácter preventivo del concepto; Gemini y Copilot logran 3 con hiperónimos válidos

² Página web: <https://chatgpt.com/>

³ Página web: <https://claude.ai/login>

⁴ Página web: <https://gemini.google.com/app?hl=es-ES>

⁵ Página web: <https://www.perplexity.ai/>

⁶ Página web: <https://copilot.microsoft.com/>

pero genéricos; ChatGPT y Claude alcanzan 4 con descriptores más precisos, aunque sin recoger la dimensión preventiva de la definición de referencia. En **C2**, todos los modelos obtienen puntuaciones bajas (2–3): ningún output recoge los rasgos nucleares de la referencia (criopreservación prematura, calidad folicular, reimplante, posposición de la menopausia). Gemini se acerca más (3) al mencionar tipos de intervención y objetivos, aunque sin los mecanismos específicos. En **C3**, Copilot obtiene 1 por incluir la etiqueta “Definición:”, negrita interna y una oferta conversacional no solicitada; Gemini obtiene 3 por exceso de extensión; el resto adopta forma definitoria correcta. En **C4**, Perplexity y Copilot obtienen 3 por léxico vago (*deterioro asociado a la edad*) o por emplear un calco informal del inglés (*estrategias de rejuvenecimiento ovárico*). En **C5**, Claude obtiene 3 por emplear *envejecimiento gonadal* sin aclarar; Gemini obtiene 3 por densidad excesiva; Copilot obtiene 3 por formato inadecuado. Ninguna definición suma el punto opcional de C6: la referencia especifica la criopreservación y el reimplante, rasgos ausentes en todas las respuestas.

Ejemplo 2. ciclo iniciado

Definición de referencia validada: Fase inicial de un tratamiento de reproducción asistida que comienza con la administración de fármacos para la estimulación ovárica o con el inicio del monitoreo ecográfico en ciclos naturales. Se considera iniciado desde el momento en que se prescribe la medicación o se realiza el primer control, independientemente de si se llega o no a la punción folicular.

Tabla 5. Definiciones generadas por los cinco modelos

Modelo	Definición generada
IA1 ChatGPT (GPT-5.5)	<i>Fase inicial de un ciclo de reproducción asistida en la que se comienza la estimulación ovárica controlada o la sincronización hormonal del endometrio para la preparación del tratamiento.</i>
IA2 Claude (Claude Sonnet 4.6)	<i>Ciclo de tratamiento de reproducción asistida en el que se ha iniciado la estimulación ovárica o la preparación endometrial, independientemente de que llegue a completarse con la punción folicular o la transferencia embrionaria.</i>
IA3 Gemini (Gemini 3 Flash)	<i>Fase preliminar de un tratamiento de reproducción asistida que comienza formalmente con la administración de la medicación para la estimulación ovárica controlada o con la monitorización ecográfica y hormonal del desarrollo folicular, independientemente de si el proceso progresa o no hasta las etapas de punción folicular, inseminación o transferencia embrionaria.</i>
IA4 Perplexity (Sonar)	<i>Ciclo iniciado: Período de estudio de un curso académico que ha comenzado formalmente y en el que el estudiante ya participa activamente en las actividades, evaluaciones y contenidos previstos para ese ciclo formativo.</i>
IA5 Copilot (GPT-5)	<i>Ciclo de estimulación ovárica en técnicas de reproducción asistida que se considera válido para iniciar un protocolo terapéutico desde la administración de la primera medicación.</i>

Tabla 6. Evaluación analítica de las definiciones — ciclo iniciado

Criterio	IA1 ChatGPT	IA2 Claude	IA3 Gemini	IA4 Perplexity	IA5 Copilot
C1. Categoría conceptual	4	5	5	0	4
C2. Rasgos distintivos	4	5	5	0	3
C3. Forma definitoria	5	5	4	4	5
C4. Precisión léxica	4	5	4	0	4

Criterio	IA1 ChatGPT	IA2 Claude	IA3 Gemini	IA4 Perplexity	IA5 Copilot
C5. Adecuación al destinatario	4	4	4	0	4
Penalización	0	0	0	-3	0
PUNTUACIÓN TOTAL (máx. 25)	21	24	22	1	20
C6. Compatibilidad con referencia (opcional, +1)	No	No	No	No	No

En **C1**, Claude y Gemini obtienen 5 puntos con hiperónimos precisos (*ciclo de tratamiento* y *fase preliminar de un tratamiento*, respectivamente); ChatGPT y Copilot obtienen 4 con *fase inicial*, correcto pero algo genérico; Perplexity obtiene 0 por desplazar el término al ámbito académico. En **C2**, Claude es el único modelo que recoge el rasgo diferencial nuclear de la definición de referencia: que el ciclo se considera iniciado con independencia de si llega o no a completarse con la punción folicular o la transferencia embrionaria. Gemini también lo incluye y obtiene 5, aunque con mayor extensión. ChatGPT (4) y Copilot (3) no explicitan esta característica. En **C3**, Gemini obtiene 4 por exceso de extensión, aunque sin enciclopedismo. ChatGPT, Claude, Copilot y Perplexity presentan una estructura formalmente definitoria; no obstante, en el caso de Perplexity esta corrección es solo formal, ya que el contenido pertenece a un dominio conceptual ajeno. el resto produce definiciones formalmente correctas. En **C4**, Perplexity obtiene 0 por emplear vocabulario del ámbito educativo (*actividades, evaluaciones, contenidos*) ajeno por completo a la terminología de reproducción asistida. En **C5**, Perplexity obtiene asimismo 0 porque para estudiantes de ciencias de la salud, la definición no orienta sobre el concepto biomédico y conduce a un campo ajeno. La penalización de -3 puntos por alucinación factual lleva la puntuación de Perplexity a 1, el resultado más bajo de los dos ejemplos. Este caso ilustra que la rúbrica permite detectar y cuantificar tanto errores de contenido conceptual, como la ausencia de un rasgo clave en el caso del *antiaging ovárico*, como errores de dominio, como el desplazamiento del término a un campo semántico ajeno en el caso del *ciclo iniciado*, y asigna penalizaciones diferenciadas según la gravedad de la desviación.

9. Conclusiones

El presente artículo ha descrito el diseño, los fundamentos metodológicos y las condiciones de replicabilidad de una rúbrica analítica destinada a evaluar las definiciones terminológicas generadas por modelos de lenguaje. El instrumento se articula en torno a seis criterios —categoría conceptual, rasgos distintivos, forma definitoria, precisión léxica, compatibilidad con la definición de referencia y adecuación al destinatario—, que operacionalizan los requisitos que toda definición terminológica de calidad debe cumplir desde una perspectiva lexicográfica y comunicativa. La rúbrica no evalúa la coincidencia literal con una referencia humana, sino la adecuación conceptual y formal de la definición generada, lo que le confiere validez independientemente del dominio de aplicación.

Entre las aplicaciones principales del instrumento cabe destacar su utilidad en estudios comparativos entre modelos de lenguaje, en el análisis del efecto de diferentes estrategias de *prompting* sobre la calidad definitoria y en tareas de revisión y control de calidad de vocabularios especializados. En el contexto docente, la rúbrica puede emplearse como herramienta de evaluación en actividades de redacción terminológica, dado que explicita los criterios que distinguen una definición terminológica canónica de una respuesta enciclopédica o conversacional. Asimismo, el

análisis de los resultados por criterio y por tipo conceptual permite identificar patrones de error recurrentes en los modelos evaluados, como el uso de hiperónimos excesivamente generales, la omisión de rasgos distintivos esenciales o la tendencia a producir respuestas de extensión y forma propias de textos divulgativos.

Existe, además, una relación bidireccional entre los criterios de la rúbrica y el diseño de los *prompts* de generación: los criterios describen operativamente la salida esperada del modelo y pueden, por ello, incorporarse como instrucciones explícitas en *prompts* orientados a la obtención de definiciones de mayor calidad terminológica. Esta dimensión del instrumento resulta de especial interés en contextos de terminografía asistida por IA, en los que la posesición y la validación experta se articulan con la generación automática.

Como toda propuesta de evaluación de base cualitativa, la rúbrica presenta limitaciones que conviene señalar. En primer lugar, la fiabilidad interevaluador depende de una fase de calibración previa: la puntuación puede variar si los evaluadores no comparten criterios sobre qué rasgos son constitutivos o accesorios en un término concreto. En segundo lugar, la validez del instrumento está condicionada por la calidad de la definición de referencia: si esta es incompleta, enciclopédica o inadecuada para el destinatario previsto, la evaluación puede producir resultados sesgados. Por ello, la selección o elaboración de referencias validadas constituye un paso previo indispensable para el uso riguroso del instrumento.

La transferibilidad del instrumento a otros dominios especializados es una de sus propiedades más relevantes. Dado que los criterios responden a principios generales de la redacción terminológica y no a contenidos propios de la reproducción asistida, la rúbrica puede replicarse en cualquier campo siempre que se adapten las fuentes de referencia, los tipos conceptuales esperables y el perfil del destinatario. La publicación del instrumento junto con los *prompts* y la ficha de evaluación —disponibles como anexos del presente artículo— en un repositorio de acceso abierto como Zenodo facilita la citación, la reutilización y el seguimiento de futuras versiones del recurso.

Contribución de las autoras (CRediT)

M. Isabel Santamaría-Pérez y Ovidia Martínez Sánchez han contribuido en igual medida a todas las fases del trabajo: conceptualización, metodología, análisis formal, investigación, recursos, redacción (borrador original), redacción (revisión y edición) y supervisión.

Referencias bibliográficas

- Alonso Ramos, M. (2023). El papel de ChatGPT como lexicógrafo. En C. Garriga Escribano, S. Iglesia Martín, J. A. Moreno Moreno y A. Nomdedeu Rull (Eds.), *Lligams. Textos dedicats a Maria Bargalló Escrivà* (pp. 15–26). Universitat Rovira i Virgili.
- De Schryver, G.-M. (2023). Generative AI and lexicography: The current state of the art using ChatGPT. *International Journal of Lexicography*, 36(4), 355–387. <https://doi.org/10.1093/ijl/ecad021>
- Fuentes Morán, M.^a T.; Domínguez Santana, F.; Travieso Rodríguez, C. (2024). La inteligencia artificial como herramienta lexicográfica: estudio analítico sobre el rendimiento de CHATGPT, COPILOT y GEMINI en unidades léxicas del español. *Revista de Lingüística Teórica y Aplicada*, 62 (1), 13-38. <https://doi.org/10.29393/RLA62-1IAMF30001>
- Fuertes-Olivera, P. A., & Tarp, S. (2025). Lexicografía innovadora: Nuevos productos y métodos en la era de la IA generativa. *Revista Internacional de Lenguas Extranjeras / International Journal of Foreign Languages*. <https://revistes.urv.cat/index.php/rile/article/view/4164>.
- Heinisch, B. (2025). *Next-gen terminology: Transforming terminology work with large language models*. *Across Languages and Cultures*, 26(S), 64-80. <https://doi.org/10.1556/084.2025.01061>
- Jakubíček, M., & Rundell, M. (2023). The end of lexicography? Can ChatGPT outperform current tools for post-editing lexicography? En *Electronic Lexicography in the 21st Century: Proceedings of the eLex 2023 Conference* (pp. 518–533). <https://elex.link/elex2023/proceedings-download/>
- Lew, R. (2023). ChatGPT as a COBUILD lexicographer. *Humanities and Social Sciences Communications*, 10, Article 704. <https://doi.org/10.1057/s41599-023-02119-6>
- Lew, R. (2025). Dictionaries and lexicography in the AI era. *Humanities and Social Sciences Communications*, 11 (1) <https://doi.org/10.1057/s41599-024-02889-7>
- Rundell, M. (2024). Automating the creation of dictionaries: Are we nearly there? *Humanising Language Teaching*, 26(1). <https://www.hltmag.co.uk/feb24/automating-the-creation-of-dictionaries>
- San Martín, A. (2024). What generative artificial intelligence means for terminological definitions. *arXiv*. <https://arxiv.org/abs/2402.16139>
- Tarp, S., & Nomdedeu-Rull, A. (2024). Who has the last word? Lessons from using ChatGPT to develop an AI-based Spanish writing assistant. *Círculo de Lingüística Aplicada a la Comunicación*, 97, 309–321. <https://doi.org/10.5209/clac.91985>
- Varela Salinas, M. J., & Godoy Lorenzatto, A. (2024). Using ChatGPT and determinologisation to enhance understanding of lung cancer information. *Lebende Sprachen*, 69(2), 412–433. <https://doi.org/10.1515/les-2024-0020>
- Vidal Sabanés, L., & Da Cunha, I. (2025). AI as a resource for the clarification of medical terminology: An analysis of its advantages and limitations. *Terminology*, 31(1), 37–71.

Anexo I. Prompts de generación de definiciones

En el estudio se emplearon dos prompts de generación con diseños complementarios. El primero, denominado *prompt controlado*, incorporaba técnica de *few-shot prompting* con instrucciones detalladas y dos definiciones de referencia a modo de ejemplo calibrado. El segundo, denominado *prompt general*, reproducía la plantilla que los lingüistas empleaban para redactar sus propias definiciones, con un único ejemplo y sin instrucciones adicionales de forma. La diferencia entre ambos permite analizar en qué medida la precisión de las instrucciones y la presencia de ejemplos calibrados influyen en la calidad definitoria de los modelos.

Prompt controlado (few-shot prompting)

CONTEXTO: Actúa como especialista en terminología biomédica y redacción lexicográfica en español. Tu tarea es redactar UNA definición terminológica de un término especializado de reproducción asistida.

DESTINATARIO: Estudiante universitario de ciencias de la salud.

OBJETIVO: Producir una definición lexicográfica clara, precisa, breve y conceptualmente correcta.

INSTRUCCIONES OBLIGATORIAS:

1. La definición debe seguir, siempre que sea posible, el patrón género próximo + diferencia específica.
2. La definición debe comenzar con un descriptor o hiperónimo adecuado del término.
3. La primera palabra debe empezar con mayúscula.
4. La definición debe terminar con punto final.
5. Debe constar de una sola oración.
6. Evita fórmulas metadiscursivas como “se refiere a”, “es un término que describe”, “podemos definirlo como”, “consiste en”.
7. Debe sonar a definición de recurso terminológico, no a respuesta de manual, chatbot o enciclopedia.
8. Mantén un nivel de especialidad adecuado para estudiantes universitarios de ciencias de la salud: preciso, pero no innecesariamente críptico.
9. Extensión recomendada: entre 15 y 30 palabras. Prioriza definiciones concisas; no obstante, si la complejidad del término exige mayor desarrollo o si es necesario incorporar información eponímica o aclaratoria esencial, puede superar esa extensión.
10. Si el término pertenece a un campo temático concreto (biología celular, anatomía, fisiología, embriología, signo/síntoma, etc.), adapta el descriptor al tipo conceptual correcto.
11. Devuelve únicamente la definición final.

EJEMPLOS DE BUENA SALIDA:

Término: ciclo menstrual

Definición: Proceso cíclico mensual de cambios hormonales en los ovarios y en el útero que abarca desde el primer día de la menstruación hasta el día anterior a la siguiente regla. Comienza con el proceso de maduración del óvulo y, si este no es fecundado, concluye con su destrucción y expulsión, lo cual genera una hemorragia (menstruación o menorrea). Comprende varias fases (folicular, ovulación, lútea y menstruación).

Término: anomalía mülleriana

Definición: Malformación congénita que afecta al aparato reproductor femenino desde el nacimiento y que generalmente afecta a las trompas de Falopio, el cuello uterino y la parte

superior de la vagina. Su tratamiento es quirúrgico. Recibe su nombre de Johannes Peter Müller, el fisiólogo que las describió por primera vez en 1830 a partir de los conductos embrionarios a partir de los cuales se desarrollan estas estructuras.

ENCARGO: Ahora redacta la definición del siguiente término:

Término: {TERMINO} / Campo temático: {CAMPO_TEMATICO}

Prompt general (basado en la plantilla humana)

CONTEXTO: Actúa como especialista en terminología biomédica y redacción lexicográfica en español. Tu tarea es redactar definiciones para un vocabulario especializado en reproducción asistida destinado a universitarios y graduados de ciencias de la salud.

ENCARGO: Redacta UNA definición terminológica según la plantilla siguiente.

PLANTILLA: La definición debe tener dos partes obligatorias: (1) **Hiperónimo** — categoría conceptual del término (p. ej.: proceso, técnica, tratamiento, trastorno, alteración). Empieza siempre con mayúscula. (2) **Descripción funcional** — qué es, para qué sirve o en qué consiste; incluye los rasgos que distinguen este término de otros similares. Extensión aproximada: entre 20 y 35 palabras. Termina con punto final. Devuelve únicamente la definición.

EJEMPLO:

Término: *fecundación artificial*

Definición: *Técnica de reproducción asistida que consiste en introducir una muestra seminal preparada en el laboratorio en la cavidad uterina para favorecer la fecundación.*

ENCARGO: Ahora redacta la definición del siguiente término:

Término: {TERMINO} / Campo temático: {CAMPO_TEMATICO}

Anexo II. Ficha mínima de evaluación por término

La siguiente ficha resume los campos mínimos que conviene conservar para facilitar la replicación del instrumento en otros dominios.

Campo	Registro
Término	
Dominio/subdominio	
Tipo conceptual	
Destinatario	
Definición de referencia	
Definición generada	
Modelo / sistema	
Prompt utilizado	
C1. Categoría conceptual	0-5
C2. Rasgos distintivos esenciales	0-5
C3. Forma definitoria	0-5
C4. Precisión léxica y especialización	0-5
C5. Adecuación al destinatario	0-5
C6. Compatibilidad con referencia (opcional, +1)	+1 (opcional)
Puntuación total	

Campo	Registro
Alucinación o error factual	Sí / No
Tipo de respuesta	Terminológica / enciclopédica / conversacional / inválida
Observaciones	

Anexo III. Escala de descriptores por criterio

Criterio	5 pt	4 pt	3 pt	2 pt	1 pt	0 pt
C1 · Categoría conceptual (hiperónimo)	El hiperónimo identifica con exactitud el tipo de entidad (técnica, procedimiento, alteración, trastorno...) y es el más específico posible dentro del ámbito de la RA.	El hiperónimo es correcto pero algo genérico (p. ej., «proceso» en lugar de «procedimiento clínico»).	El hiperónimo permite identificar la categoría aunque con imprecisión o ambigüedad moderada.	El hiperónimo es demasiado genérico o aplicable a múltiples dominios sin especificar el de la RA.	El hiperónimo es incorrecto o inadecuado para el tipo conceptual del término.	No hay hiperónimo o el término se define con una oración que no comienza con una categoría conceptual.
C2 · Rasgos distintivos esenciales (diferencia específica)	Incluye todos los rasgos nucleares que permiten distinguir el término de conceptos próximos dentro del mismo campo; no faltan rasgos imprescindibles.	Incluye los rasgos esenciales; falta algún rasgo secundario pero no compromete la delimitación conceptual.	Incluye al menos un rasgo diferenciador relevante pero omite otros importantes; la delimitación es parcial.	Los rasgos incluidos son demasiado generales o corresponden a la categoría hiperónima, no al concepto específico.	Los rasgos son escasos, erróneos o irrelevantes; la definición podría aplicarse a otro concepto próximo.	No se aportan rasgos diferenciadores; la definición es solo el hiperónimo o equivale a cero información conceptual.
C3 · Forma definitoria (adecuación lexicográfica y terminográfica)	Formulación definitoria canónica: una oración, sintética, sin metadiscurso, sin enciclopedismo o ni contenido añadido no solicitado; respeta el patrón género próximo + diferencia específica; extensión adecuada (12-30 palabras o	Formulación mayoritariamente correcta; admite algún elemento accesorio leve o ligero exceso de extensión que no distorsiona la definición.	Definición reconocible, pero con una o dos desviaciones formales: leve enciclopedismo, oración secundaria añadida, ejemplo no imprescindible o inicio con metadiscurso evitable.	La respuesta tiene aspecto de explicación o de texto de manual antes que de definición terminológica; incluye desarrollos, ejemplos o información no solicitada.	La respuesta es claramente conversacional, enciclopédica o de chatbot; añade contenido ajeno al encargo y no adopta forma de definición terminológica.	La respuesta no constituye ningún tipo de definición; es una pregunta, un error, una respuesta vacía o fuera de contexto.

Criterio	5 pt	4 pt	3 pt	2 pt	1 pt	0 pt
	justificadamen te mayor).					
C4 · Precisión léxica y especializació n	El léxico es plenamente adecuado al ámbito de la RA; usa terminología especializada correcta y comprensible para estudiantes universitarios de ciencias de la salud.	El léxico es adecuado; algún término podría ser más preciso o hay una leve oscilación entre registro técnico y general.	El léxico es aceptable en general pero incluye algún término vago, coloquial, no explicado o excesivament e técnico que reduce la precisión.	El léxico es poco especializado, vago o contiene errores terminológicos que distorsionan el significado o dificultan la comprensión del destinatario.	El léxico es inapropiado para el ámbito o incorrecto en términos técnicos (terminología confundida, malformada, inventada o innecesariamen te opaca).	El léxico es completament e inadecuado o ininteligible en el contexto de la RA.
C5 · Adecuación al destinatario (principio de adecuación terminológica)	La definición se adapta plenamente a estudiantes universitarios de ciencias de la salud: explica o desarrolla siglas relevantes, evita presuposicion es excesivas e incorpora sinónimos esenciales cuando facilitan la identificación del concepto.	Adecuada para el destinatario; puede faltar una aclaración menor de una sigla o sinónimo, sin afectar a la comprensión global.	Adecuación parcial: el concepto se entiende, pero alguna sigla, denominación alternativa o tecnicismo importante queda sin aclarar.	Adecuación débil: presupone conocimientos no garantizados o usa tecnicismos/sigl as sin apoyo suficiente para el destinatario.	Poco adecuada: omite aclaraciones terminológicas básicas o formula la definición para un público demasiado experto o demasiado general.	Inadecuada para el destinatario: oscura, excesivament e técnica, infantilizada o incapaz de orientar a estudiantes universitarios.
C6 · Compatibilid ad con la definición de referencia validada (opcional)	+1 pt La definición conserva el núcleo conceptual de la definición de referencia, no contradice sus rasgos esenciales ni reduce de forma problemática el alcance del término. Puede expresarse con otras palabras, siempre que se mantenga la equivalencia conceptual básica.			0 pt El punto adicional no se concede cuando la definición omite un rasgo nuclear de la referencia, introduce una contradicción conceptual, desplaza el término a otro dominio, restringe o amplía indebidamente su alcance o no existe una referencia validada que permita comprobar la compatibilidad.		

El criterio C6 tiene carácter opcional y solo debe aplicarse cuando se disponga de una definición de referencia validada para el término evaluado. Su puntuación no forma parte de la escala básica de 0 a 25 puntos, sino que añade un punto adicional cuando la definición generada es compatible con la referencia. Por tanto, la puntuación máxima posible pasa a ser de 26 puntos en los casos en que se aplique este criterio.

Anexo IV. Escala de puntuación total

Puntuación total	Valoración	Descripción
22–26	Excelente	La definición es conceptualmente correcta, está bien estructurada, es terminológicamente precisa, adecuada para el destinatario universitario y, cuando se aplica C6, es compatible con la definición de referencia.
17–21	Buena	La definición es correcta en lo esencial, aunque puede presentar alguna imprecisión menor, una simplificación que no supone un problema o una falta de compatibilidad parcial con algún rasgo secundario de la referencia.
12–16	Aceptable	La definición permite identificar el concepto, aunque presenta limitaciones en los rasgos distintivos, la precisión léxica, la forma definitoria, la adecuación al destinatario o la compatibilidad con la referencia.
7–11	Insuficiente	La definición solo recoge parcialmente el concepto o lo formula de manera demasiado general, poco especializada o débilmente compatible con la referencia.
1–6	Deficiente	La definición contiene errores importantes relacionados con el contenido, la forma, la especialización y la adecuación al destinatario, y presenta contradicciones relevantes con la referencia.
0	Inválida	La definición no define el término de manera reconocible, lo contradice gravemente, lo desplaza a otro ámbito o no responde al encargo.

La puntuación total se calcula sumando los criterios C1-C5, con un máximo de 25 puntos, y añadiendo, en su caso, el punto opcional del criterio C6 por compatibilidad con una definición de referencia validada. Por tanto, la puntuación máxima ajustada es de 26 puntos. Las penalizaciones por errores graves se restan una vez calculada la puntuación total y deben estar justificadas en las observaciones del evaluador.